

Отчет нормализации базы данных

Исходные данные

Исходный датасет представляет собой денормализованную таблицу где каждая строка описывает одновременно заказ, позицию в заказе и курьера. Так, например один заказ с тремя товарами и одним курьером занимает три строки, при этом данные о самом заказе, пользователе и магазине дублируются в каждой из них.


Выбор нормальной формы

Схема приведена до третьей нормальной формы (3NF).

1NF — все значения атомарны, нет повторяющихся групп колонок.

2NF — устранены частичные зависимости. В исходной таблице составным ключом фактически является тройка (`order_id`, `item_id`, `driver_id`). Атрибуты вроде `user_phone` или `store_address` зависят только от части этого ключа. Вынес их в отдельные таблицы.

3NF — устранены зависимости. Например, `item_category` зависит от `item_title`, а не напрямую от ключа строки — вынес в таблицу `items`.



Декомпозиция

users — пользователь однозначно определяет свой номер телефона. Телефоны приведены к единому формату +7XXXXXXXXXX при загрузке, так как в исходных данных встречались разные форматы записи.

stores — три магазина сети.

drivers — 390 курьеров. Телефон курьера зависит только от `driver_id`, также приведён к единому формату.

items — 18 товаров в 6 категориях.

addresses — адреса доставки. В исходных данных адрес хранился как строка без идентификатора. Добавлен суррогатный ключ `address_id`. При загрузке применяется `strip()` для удаления лишних пробелов.

orders — основная таблица заказов. Содержит атрибуты уровня заказа: временные метки, тип оплаты, скидку, причину отмены.

order_drivers — связь заказа и курьера. В данных встречается смена курьера (649 заказов). Для снятого курьера delivered_at не проставляется, поэтому введен флаг is_final который указывает на курьера фактически выполнившего доставку.

order_items — позиции заказа. Каждая строка описывает конкретный товар в конкретном заказе с количеством, ценой и скидкой на товар. Поле item_replaced_id — ссылка на item_id товара-замены. При замене в исходных данных присутствуют обе записи: исходный товар и товар замены через item_replaced_id.